

Precision and Recall for Time Series

Nesime Tatbul * Intel Labs and MIT

Tae Jun Lee * Microsoft

Stan Zdonik Brown University

Mejbah Alam Intel Labs

Justin Gottschlich Intel Labs

目次

1 概要

2 モデルの紹介

3 実験

Precision and Recall for Time Series

どんなもの？

ポイントベースの異常検知では現実に対応しきれないので、
範囲ベースの異常検知に対応する為に「Precision」「Recall」を改善した数学モデル
表現力、柔軟性、拡張性を意識した新しい数学モデル。

どうやって有効だと検証した？

従来のモデルと比較して7種類のデータセットを使用。
全て単変量の時系列データで、タクシー集客率、ツイート数、産業用機械の温度センサー等を使い、テンソフローのLSTM-ADを学習機とした。
各パラメータを変更することで、様々な異常予測値のスコアを出すことが出来た。

技術の手法や肝は？

パラメータの追加

Existence: 少しでも異常を捉えること自体に重みを置く

Size: 異常検知出来た数。

Position: 場所ごとに重みを置く。

Cardinality: 1つの予測幅内で2つ以上の異常が検知が出来た時に重み付け

議論はある？

多分無い。

先行研究と比べて何がすごい？

異常の位置を考慮に入れている。

更にその位置を調整することが出来るので、ドメインによって必要な位置に重みを置くことが出来る。

次に読むべき論文は？

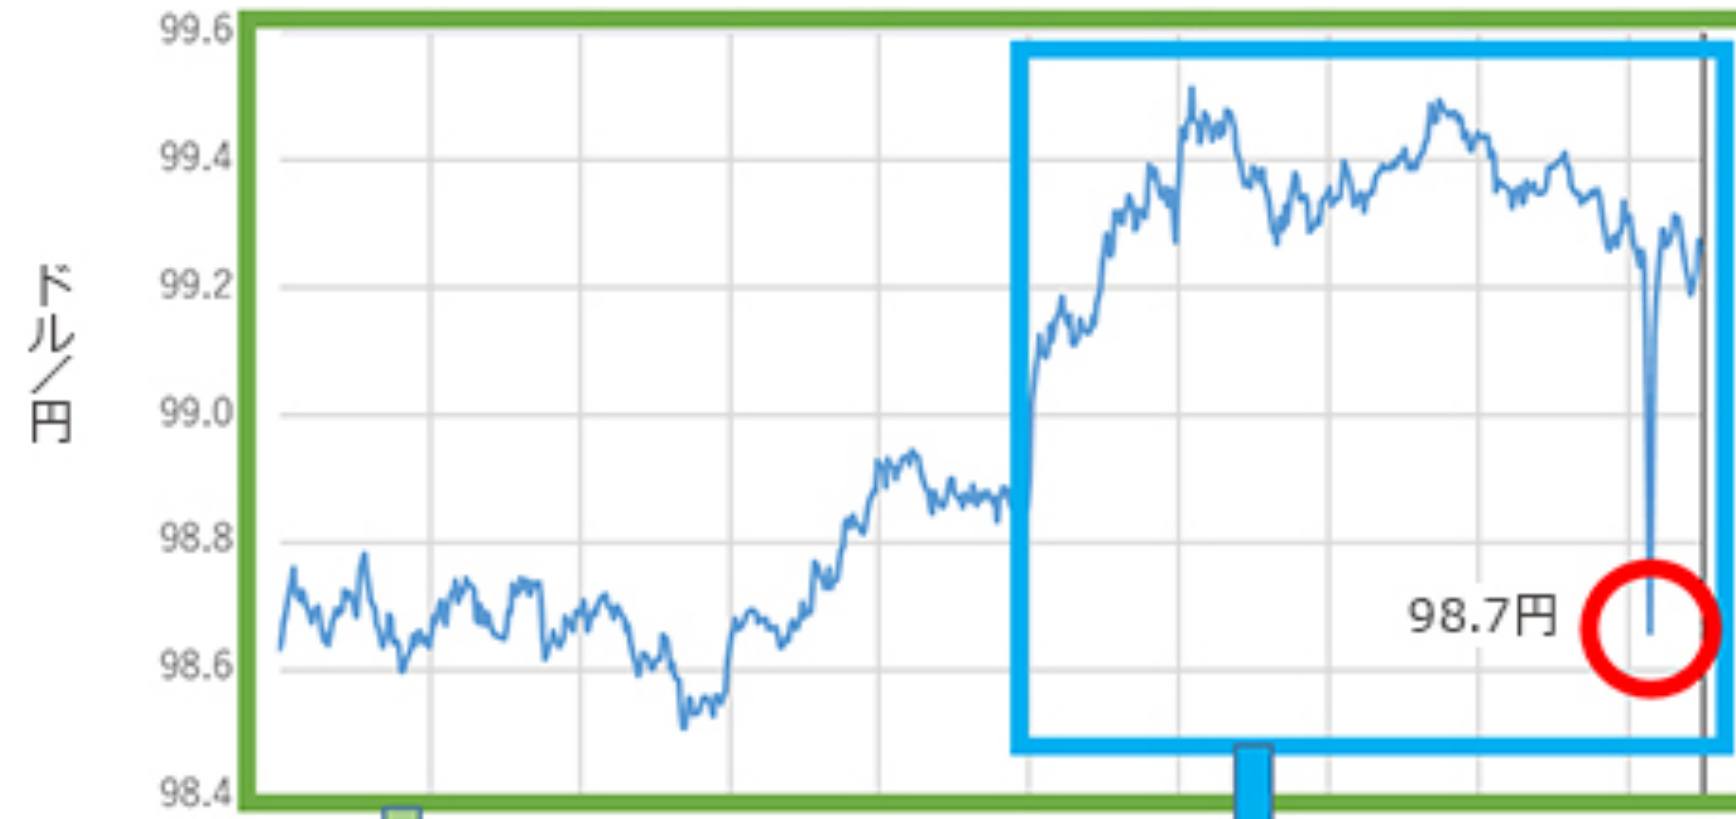
G. H. Chen, S. Nikolov, and D. Shah.

「A Latent Source Model for Nonparametric Time Series Classification」

P. Malhotra, A. Ramakrishnan, G. Anand, L. Vig, P. Agarwal, and G. Shroff.

「LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection.」

時系列データにおける異常検知



「他の大多数のデータとは振る舞いが異なるデータを検出する技術」

「サイバー攻撃の驚異検出」、「クレジットの不正利用検知」、「医療分野における早期診断」等様々なドメインで

「異常」を検知することはとても重要

$$Precision = TP \div (TP + FP)$$

$$Recall = TP \div (TP + FN)$$

precision

適合率。正と予測したデータのうち、実際に正であるものの割合。

recall

再現率。実際に正であるもののうち、正であると予測されたものの割合。

問題点

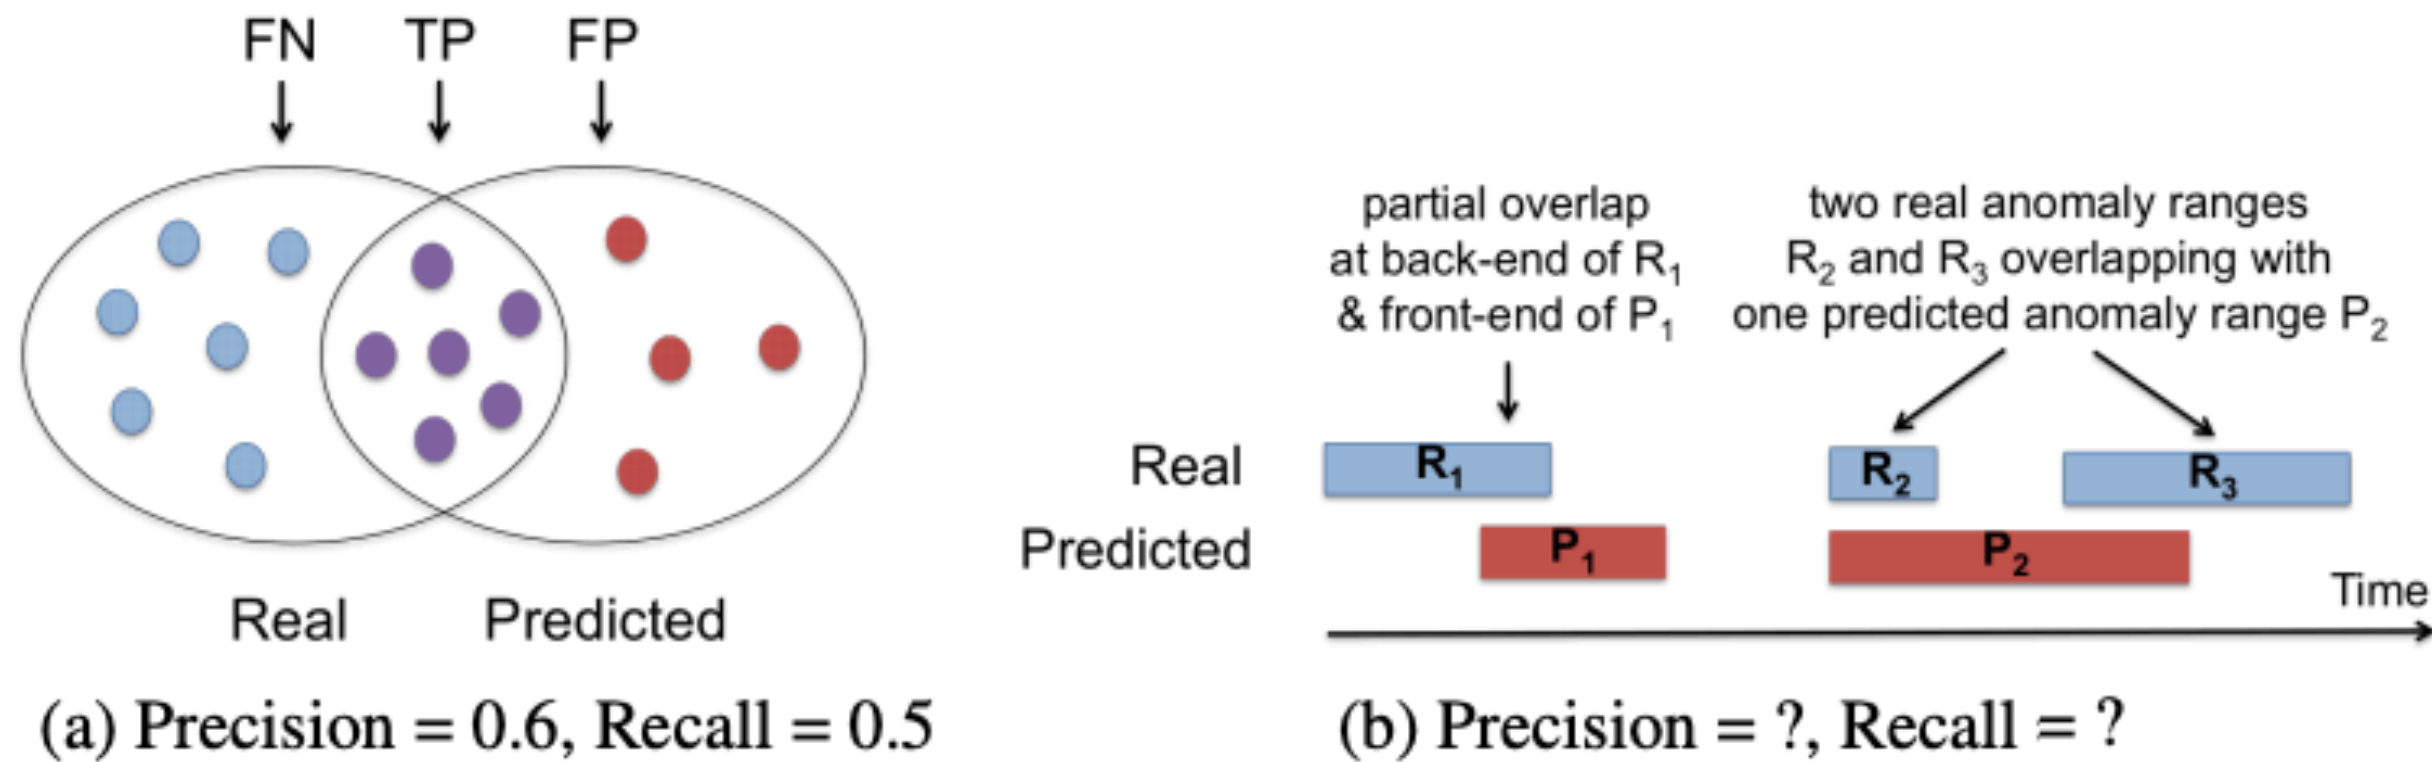


Figure 1: Point-based vs. range-based anomalies.

実世界の異常は連続して一定期間にわたる

古典的な評価手法ではポイントベースでの評価になってしまう。
範囲ベースでの異常を正しく評価することが出来ない。

そこで

新たな評価モデル

モデル

Notation	Description
R, R_i	set of real anomaly ranges, the i^{th} real anomaly range
P, P_j	set of predicted anomaly ranges, the j^{th} predicted anomaly range
N, N_r, N_p	number of all points, number of real anomaly ranges, number of predicted anomaly ranges

数式達

R : 実際に起きた異常範囲

P : 予測した異常範囲

N, Nr, Np : 全体の点の合計, 実際に起きた異常範囲の合計, 予測した異常範囲の合計

Recallの提案モデル

$$Recall_T(R, P) = \frac{\sum_{i=1}^{N_r} Recall_T(R_i, P)}{N_r}$$

基本的なモデル

1. 実際の異常と予測した異常の全ての組に対してリコールを計算する。
2. 合計スコアを実際の異常の総数で割って、平均化する。

この部分では古典的なモデルと変わらない。
一つ一つのリコールを計算する際に工夫する。

新たなパラメータの追加

- *Existence*: Catching the existence of an anomaly (even by predicting only a single point in R_i), by itself, might be valuable for the application.
- *Size*: The larger the size of the correctly predicted portion of R_i , the higher the recall score.
- *Position*: In some cases, not only size, but also the relative position of the correctly predicted portion of R_i might matter to the application.
- *Cardinality*: Detecting R_i with a single prediction range $P_j \in P$ may be more valuable than doing so with multiple different ranges in P in a fragmented manner.

4つのパラメータ

Existence: 少なくとも異常を捉えること自体に重みを置く

Size: 異常検知出来た数。

Position: 異常のある場所ごとに重みを変える。

Cardinality: 1つの予測幅内で2つ以上の異常が検知が出来た時に重み付け

α	relative weight of existence reward
$\gamma(), \omega(), \delta()$	overlap cardinality function, overlap size function, positional bias function

Existence

α	relative weight of existence reward
----------	-------------------------------------

こっちは次のページで計算

$$Recall_T(R_i, P) = \alpha \times ExistenceReward(R_i, P) + (1 - \alpha) \times OverlapReward(R_i, P) \quad (4)$$

If anomaly range R_i is identified (i.e., $|R_i \cap P_j| \geq 1$ across all $P_j \in P$), then a reward is earned.

$$ExistenceReward(R_i, P) = \begin{cases} 1, & \text{if } \sum_{j=1}^{N_p} |R_i \cap P_j| \geq 1 \\ 0, & \text{otherwise} \end{cases} \quad (5)$$

1点異常検知しただけでも偉いパラメータ

1点だけでも予測出来たら1,何も予測出来ないときは0を返す。

そこに α を掛けて重み付けする。

基本は0

SizeとPosition

Size(ただ足してるだけ)

```
function  $\omega$ (AnomalyRange, OverlapSet,  $\delta$ )  
  MyValue  $\leftarrow$  0  
  MaxValue  $\leftarrow$  0  
  AnomalyLength  $\leftarrow$  length(AnomalyRange)  
  for i  $\leftarrow$  1, AnomalyLength do  
    Bias  $\leftarrow$   $\delta$ (i, AnomalyLength)  
    MaxValue  $\leftarrow$  MaxValue + Bias  
    if AnomalyRange[i] in OverlapSet then  
      MyValue  $\leftarrow$  MyValue + Bias  
  return MyValue/MaxValue
```

(a) Overlap size

Position(前半、後半、中盤に重み付け出来る)

```
function  $\delta$ (i, AnomalyLength)  $\triangleright$  Flat bias  
  return 1  
function  $\delta$ (i, AnomalyLength)  $\triangleright$  Front-end bias  
  return AnomalyLength - i + 1  
function  $\delta$ (i, AnomalyLength)  $\triangleright$  Back-end bias  
  return i  
function  $\delta$ (i, AnomalyLength)  $\triangleright$  Middle bias  
  if i  $\leq$  AnomalyLength/2 then  
    return i  
  else  
    return AnomalyLength - i + 1
```

(b) Positional bias

Figure 2: Example definitions for $\omega()$ and $\delta()$ functions.

異常検知の場所に重みをつける

検知された異常をPositionフェーズで重みをつけて、Sizeフェーズでそれぞれ足していくだけ

Cardinality

$$OverlapReward(R_i, P) = \boxed{CardinalityFactor(R_i, P)} \times \sum_{j=1}^{N_p} \omega(R_i, R_i \cap P_j, \delta) \quad (6)$$

When R_i overlaps with only one predicted anomaly range, the cardinality factor reward is the largest (i.e., 1). Otherwise, it receives $0 \leq \gamma() \leq 1$ defined by the application.

$$\boxed{CardinalityFactor(R_i, P) = \begin{cases} 1 & , \text{ if } R_i \text{ overlaps with at most one } P_j \in P \\ \gamma(R_i, P), & \text{ otherwise} \end{cases}} \quad (7)$$

1つの予測幅で**複数**の異常を検知した場合に重み付け

$$\gamma = 1 / x$$

とするのがちょうど良い。

例) 1つの予測幅に3つの異常幅が見られた場合は $1 / 3$ となる。

ワンセットを予測してようやく 1 となる。

数式まとめ

$$\boxed{CardinalityFactor(R_i, P)} = \begin{cases} 1 & , \text{ if } R_i \text{ overlaps with at most one } P_j \in P \\ \gamma(R_i, P), & \text{ otherwise} \end{cases} \quad (7)$$

$$\boxed{OverlapReward(R_i, P)} = CardinalityFactor(R_i, P) \times \sum_{j=1}^{N_p} \omega(R_i, R_i \cap P_j, \delta) \quad (6)$$

$$\boxed{ExistenceReward(R_i, P)} = \begin{cases} 1, & \text{ if } \sum_{j=1}^{N_p} |R_i \cap P_j| \geq 1 \\ 0, & \text{ otherwise} \end{cases} \quad (5)$$

$$Recall_T(R_i, P) = \boxed{\alpha \times ExistenceReward(R_i, P)} + \boxed{(1 - \alpha) \times OverlapReward(R_i, P)} \quad (4)$$


$$Recall_T(R, P) = \frac{\sum_{i=1}^{N_r} Recall_T(R_i, P)}{N_r}$$

Prediction

Recallとおなじ

実験

古典的モデルと比較



(a) Recall

7つのデータを使用

全て単変量の時系列データを使用

パラメータ

$\alpha = 0$, $\gamma() = 1$, $\omega()$ is as in Figure 2a

Recall_Classical = 従来の古典的モデル。

Recall_T_Classical = 新しい提案モデルのフラットパラメータ。

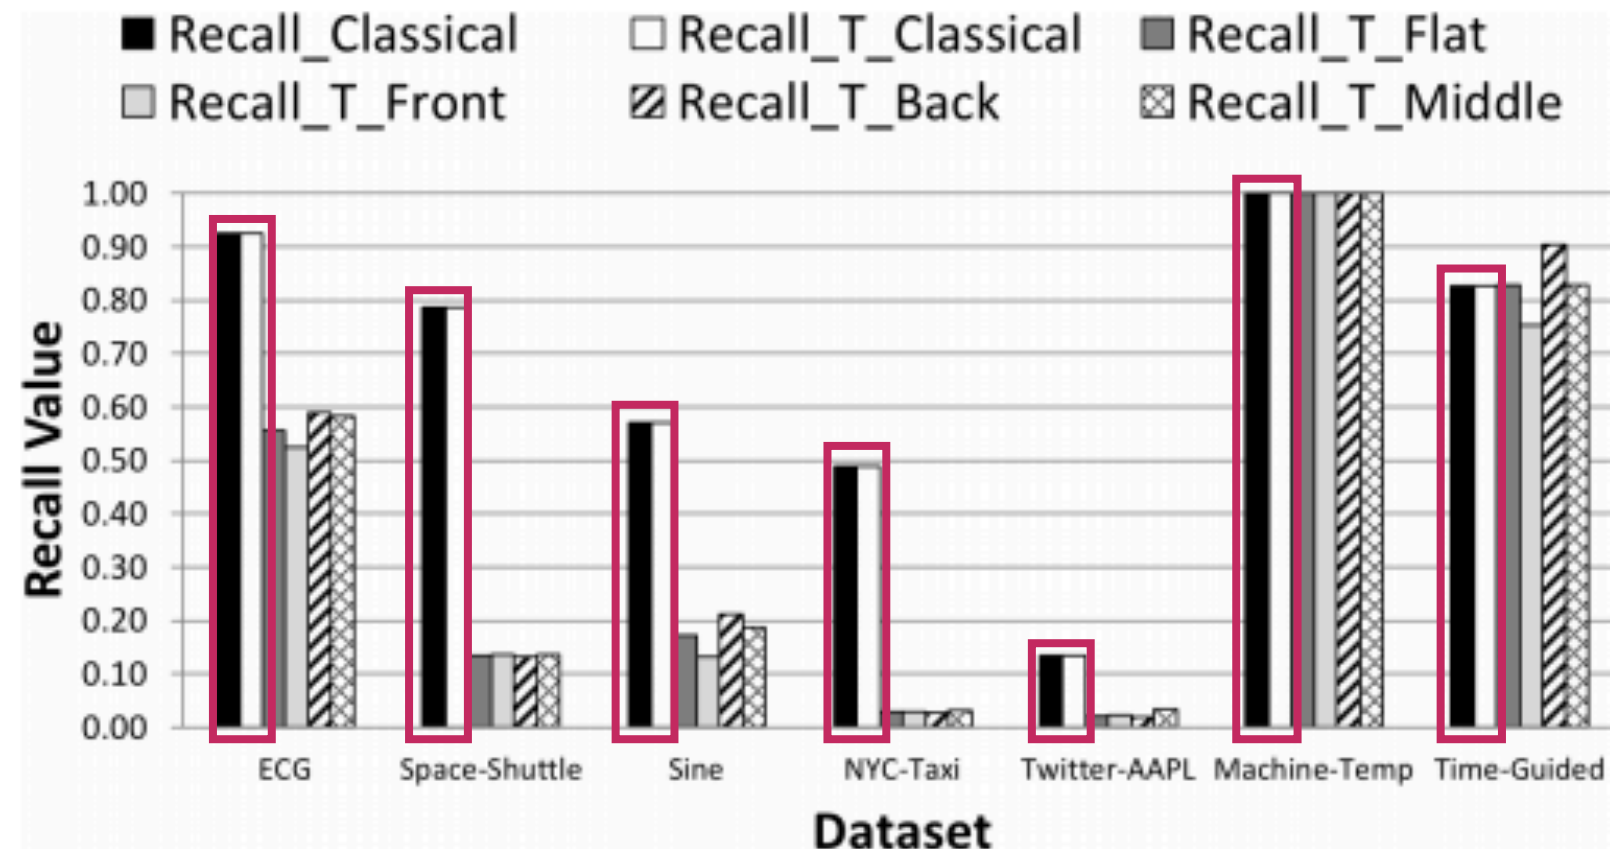
Recall_T_Flat = cardinalyパラメータのみ追加。

Recall_T_Front = 早めの異常に重み

Recall_T_Back = 遅めの異常に重み

Recall_T_Middle = 中間の異常に重み

古典的モデルと比較



(a) Recall

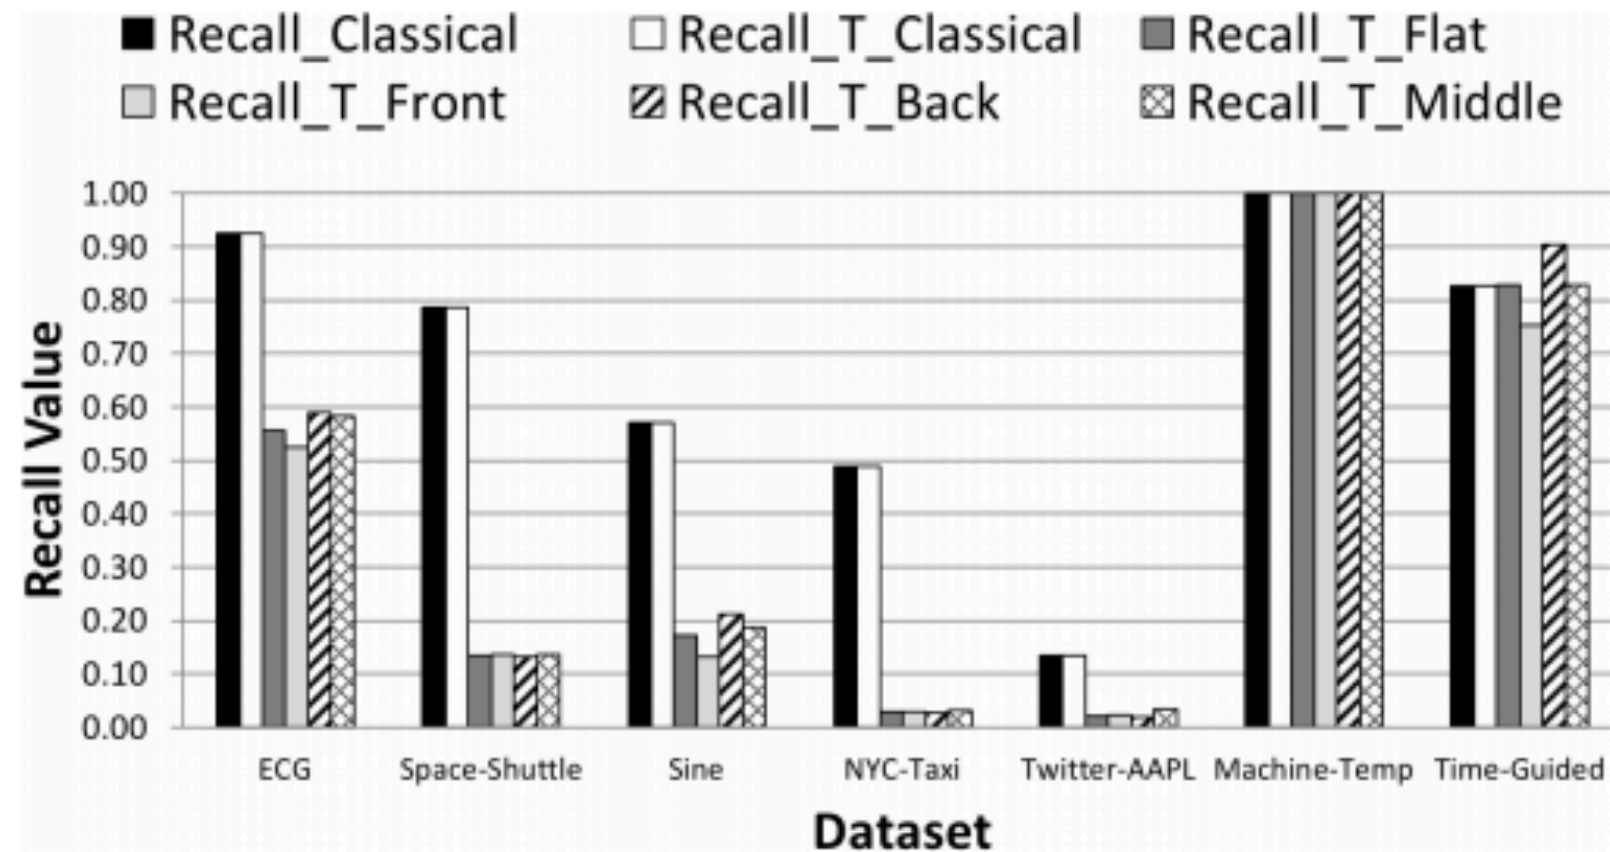
新モデルは旧モデルを包含

$\text{Recall_Classical} = \text{Recall_T_Classical}$

旧モデルと、新モデルのパラメータフラットのものとは全て数字が変わらない

→新モデルを使うことで、旧モデルの表現は可能。

古典的モデルと比較



(a) Recall

カーディナリー係数によって縮小

カーディナリティ係数を使っているモデルは、recallが縮小する。

重複しているデータに対して、報酬を軽くしているから。

幅をひろくにとって異常予測をするとこんな感じに縮小する。

古典的モデルではこんな表現は不可能だった。

他のモデルと比較(Numentaモデル)

Table 2: Sensitivity to positional bias

	Numenta_Standard	F1_T_Front_Flat	F1_T_Back_Flat
Front-Predicted	0.67	0.42	0.11
Back-Predicted	0.63	0.11	0.42

新しいモデルのほうが、位置の偏りに敏感

Numentaモデルは早期発見の為に設計されたモデル

位置に偏りがあるデータを入れてみた場合、提案モデルのほうがそれぞれ敏感に反応することが出来るので、多彩な表現力を持つ。

他にも、

色々実験やってたけど結局はなに？

つまりは

拡張性と表現力が高いモデルとなった。

ドメインごとに、時系列データの異常に関して、**異常の位置や、重複している部分**が重要だったり異なる。

このモデルは**パラメータを調整**することで、それぞれのドメインにあった**様々な基準**で評価することが出来る。

参照

- 論文元
<https://arxiv.org/pdf/1803.03639v3.pdf>
- Albert(時系列データにおける異常検知)
https://www.albert2005.co.jp/knowledge/machine_learning/anomaly_detection_basics/anomaly_detection_time